Pontificia Universidad Católica de Chile
Escuela de Ingeniería
IIC-3694 Inteligencia Artificial Generativa

Razonamiento cuantitativo con unidades

Desafío de investigación

Fernando Fajardo, Sebastian Palma, Benjamin Prieto y Rodrigo Ugarte · 7 de noviembre de 2026

1. Problema y alcance

Este trabajo construye un entorno que genera problemas cuantitativos en español y comprueba automáticamente las respuestas de modelos de lenguaje. El objetivo es preparar datos y una función de recompensa para entrenar posteriormente a Qwen3-1.7B, sin realizar entrenamiento en esta entrega. Cada problema proporciona fórmulas y equivalencias de unidades para evaluar cálculo y composición de operaciones, en lugar de memoria de conocimientos físicos.

Las 180 tareas se reparten entre entrenamiento, validación y prueba. Tras calibrar su dificultad con Qwen3-1.7B, se generan datos de entrenamiento y se compara su desempeño inicial con Llama 3.2-1B, SmolLM2-1.7B-Instruct y Qwen3-8B, además de DeepSeek-V4-Pro-0813 como referencia externa. Qwen3-8B actúa como *modelo generador*: produce soluciones candidatas para construir las trazas SFT y los pares DPO destinados al entrenamiento posterior de Qwen3-1.7B. El verificador las filtra con respuestas de referencia calculadas por código. Todos responden en un turno, sin calculadora, intérprete ni otras herramientas.

2. Diseño del dataset

Llamamos *familia* a un tipo de problema definido por sus magnitudes y fórmula. Las tres familias son una elección de este trabajo, no categorías impuestas por el desafío: velocidad, $v = d/t$; energía cinética, $E = mv^2/2$; y luminosidad, $L = 4\pi d^2 F$. Aquí d es distancia, t tiempo, m masa, v velocidad, E energía, L luminosidad y F flujo de energía recibido por unidad de superficie. Permiten contrastar una división con cálculos que incorporan cuadrados y productos, manteniendo respuestas verificables por código.

Cada familia combina dos estructuras: datos directos o suma de dos componentes positivos, como $d_1 + d_2$, $m_1 + m_2$ o $F_1 + F_2$. Sobre cada problema físico se construyen tres tareas equivalentes: fácil usa unidades del Sistema Internacional (SI) sin conversiones, media convierte una entrada y difícil convierte dos entradas y, en velocidad y energía, también la salida. En luminosidad difícil se mantiene la salida en W, por lo que hay dos conversiones. Estos niveles describen operaciones previstas, no garantizan un orden de dificultad para todos los modelos.

El generador, incluido en `code/src/challenge/generator.py` del paquete, muestrea distancias de 101–9999 m y tiempos de 7–199 s para velocidad, masas de 1,1–49,9 kg y velocidades de 1,1–49,9 m/s para energía, y distancias enteras de 2–30 m con flujos de 0,01–0,99 $\mathrm{W/m^2}$ para luminosidad. Las sumas reparten el total en fracciones entre 0,2 y 0,8, y los valores se imprimen con hasta 15 cifras significativas. Se excluyen cero, negativos e incertidumbres físicas. La generación reproducible y la sensibilidad a variantes tienen como antecedentes Reasoning Gym, de Stojanovski et al. (2025) [1], y GSM-Symbolic, de Mirzadeh et al. (2024) [2].

Se generan 20 problemas físicos por familia con semilla 4301 y se distribuyen con semilla 4302, manteniendo juntas sus tres variantes para evitar que una misma situación aparezca tanto en entrenamiento como en prueba. Así se obtienen 60 problemas físicos y $60 \times 3 = 180$ tareas. La tabla 1 explicita el reparto, elegido antes de evaluar para cubrir cada combinación de familia y nivel con una carga de inferencia local acotada.

Train se usa para generar soluciones y pares de preferencias para entrenamiento, eval queda reservado para validación y test mide el desempeño final. Ningún problema utilizado durante el desarrollo o la calibración integra estas particiones. Las plantillas sí son compartidas, por lo que se evalúan nuevas magnitudes y combinaciones, no generalización a otros tipos de problemas o redacciones arbitrarias.

Partición	Problemas por familia	Tareas por familia	Por nivel/familia	Total
Train	10	30	10	90
Eval	4	12	4	36
Test	6	18	6	54
Total	20	60	20	180

Cuadro 1: Cada partición contiene las tres familias y conserva juntas las variantes fácil, media y difícil de cada problema. Las estructuras directa y suma se balancean.

Como muestra de una tarea de velocidad de nivel medio, se entregan $d_1 = 4{,}08$ km, $d_2 = 1{,}02$ km, $t = 88$ s y la fórmula $v = (d_1 + d_2)/t$, y se pide el resultado en m/s. Tras convertir las distancias, la respuesta esperada es 5100/88 m/s y una salida válida es `{"value":57.95,"unit":"m/s"}`. Cada tarea solicita hasta 80 palabras de explicación y un único resultado final. Para decidir automáticamente si esa salida es correcta se aplica el siguiente procedimiento, común a todos los modelos.

3. Verificación de respuestas y limitaciones

La función `reward(prompt, completion)` recibe el enunciado y la respuesta del modelo y devuelve 1 si la considera correcta o 0 en caso contrario. Los resultados esperados se calculan mediante las fórmulas del generador y se comprueban con un segundo cálculo que interpreta los datos impresos en el enunciado, usando tolerancia relativa 10^{-10}. Se guardan por separado en `data/tasks/private/`: son referencias de evaluación que el modelo no recibe. Antes de llamar a `reward`, el programa consumidor lee esos archivos y registra las tareas con `load_tasks`, función incluida en `code/src/challenge/verifier.py`. Un enunciado no registrado produce `ValueError`, que indica un error de integración.

El extractor identifica un resultado final en JSON con número y unidad o como cantidad seguida de unidad, sin consultar la solución ni ejecutar expresiones. Después convierte la cantidad a SI, por ejemplo de km/h a m/s, y comprueba que corresponda a la magnitud pedida y sea finita. Si y es el valor obtenido y y^* el esperado, ambos en SI, la condición de aceptación es $|y - y^*| \leq 0{,}01|y^*|$. Esta tolerancia del 1 % admite redondeo, pero no certifica la explicación. Se admiten m/s y km/h para velocidad, J, kJ y erg para energía, y W, kW, erg/s y luminosidades solares para luminosidad.

Las respuestas se clasifican como correctas (`correct`), numéricamente incorrectas (`numeric`), de magnitud incompatible (`unit`) o no interpretadas (`unparsed`). Esta última categoría aparece ante formatos no reconocidos, resultados ambiguos o ausencia de una cantidad final admisible, y no demuestra un error matemático. La *cobertura* es la proporción de respuestas que el extractor logra interpretar. También se registran las salidas cortadas por el límite de generación y los intentos incompletos, sin excluirlos del cálculo de resultados.

El código de verificación entregado se fijó antes de iniciar test y no se modificó al observar sus respuestas. Las pruebas incluyen cantidades equivalentes como 22 m/s y 79,2 km/h y rechazos de alternativas, resultados contradictorios, unidades incompatibles, claves JSON duplicadas y números no finitos, sin rescatar un valor previo por coincidir con la solución.

Persisten tres límites importantes. Primero, se acepta una unidad físicamente equivalente aunque difiera de la solicitada, lo que permite omitir la conversión de salida. Exigirla reduciría los aciertos de Llama de cuatro a tres. Segundo, coma y punto se leen como decimales, de modo que `1,000 J` significa 1 J, sin que el enunciado descarte explícitamente separadores de miles. Además, alias como `joule`, `kph` y `Km/h`, números en palabras, ciertos superíndices y expresiones LaTeX quedan sin interpretar. Tercero, aunque la inferencia limita la salida a 1024 tokens, la función de recompensa no impone su propio máximo de longitud.

También se confirmaron siete falsos negativos entre el objetivo y Qwen3-8B por líneas intermedias que invalidan un JSON final numéricamente correcto. Este diagnóstico posterior a test no cambia las métricas ni valida el razonamiento. Para mostrar cuánto podría afectar la extracción, las tablas incluyen una cota optimista que supone correctas todas las respuestas no interpretadas, sin presentarla como intervalo de confianza. Antes de entrenar será necesario ampliar las pruebas y precisar las reglas de formato y unidad, y cualquier evaluador ajustado con estos casos deberá medirse sobre un nuevo conjunto reservado si se desea una evaluación independiente.

4. Calibración y protocolo experimental

Una vez definido el verificador, se comprobó si las tareas daban al objetivo Qwen3-1.7B una mezcla de aciertos y errores que justificara entrenarlo después. Para ello se realizaron pruebas preliminares separadas del dataset final y se ajustó luminosidad, cuya proporción de aciertos estaba cerca de cero. Se redujeron sus magnitudes y se eliminó la conversión de salida del nivel difícil, repitiendo la generación de respuestas cuando cambiaba el enunciado.

El resultado consolidado de esta calibración reúne 30 problemas físicos, 10 por familia, con tres niveles cada uno: 90 tareas. Qwen3-1.7B respondió tres veces cada tarea, produciendo $90 \times 3 = 270$ intentos. Se emplean tres muestras para medir tanto el acierto de una respuesta individual (pass@1) como la proporción de tareas resueltas al menos una vez entre tres intentos (pass@3). Hubo 132 aciertos, 126 errores numéricos y 12 respuestas no interpretadas, por lo que pass@1 fue $132/270 = 48{,}89\,\%$, pass@3 fue $59/90 = 65{,}56\,\%$ y la cobertura fue $258/270 = 95{,}56\,\%$. Los tres truncamientos observados permanecieron en esos denominadores.

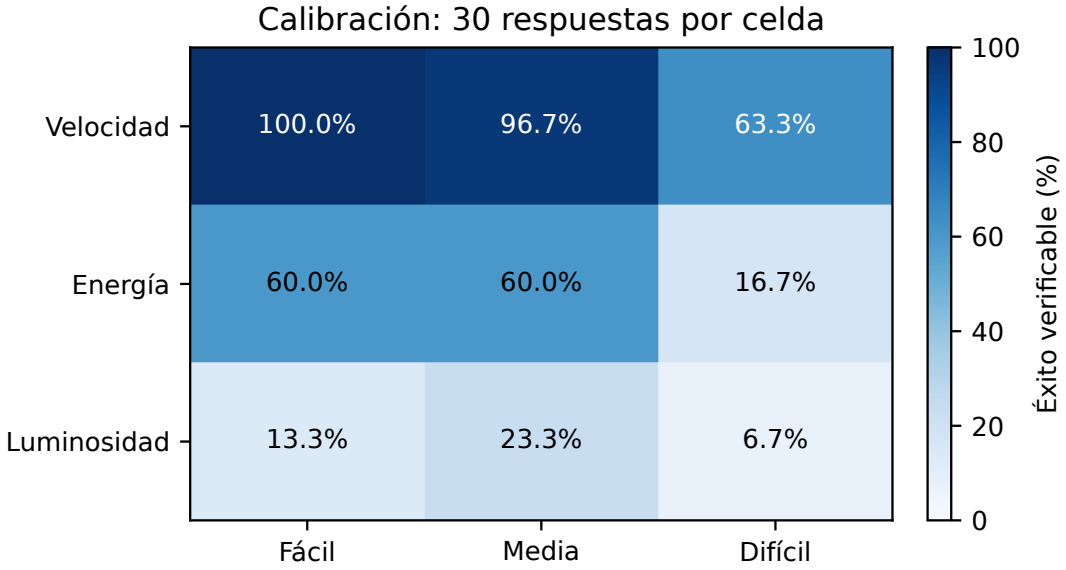


Figura 1: Calibración de Qwen3-1.7B antes de fijar el test. Cada combinación de familia y nivel contiene 10 tareas y 30 respuestas.

Luminosidad difícil conservó solo 2/30 aciertos y se mantuvo para estudiar una condición especialmente exigente, mientras velocidad fácil alcanzó 30/30 y sirvió como control sencillo. Velocidad difícil obtuvo 19/30, y los promedios fácil y medio fueron 57,78 % y 60,00 %. Hay señal de acierto y error global, pero no calibración suficiente en todas las combinaciones ni un orden estricto entre niveles. Con estas limitaciones se fijaron las tareas finales y el procedimiento empleado tanto para generar datos como para medir la línea base.

Las inferencias locales se ejecutaron de forma secuencial en un equipo Intel Core 5 210H con 12 CPU lógicas, 30,47 GiB de RAM y GPU RTX 3050 Laptop de 6 GiB, usando Ollama 0.18.0 y Python 3.12.13. Se utilizaron pesos en formato GGUF con cuantización Q4_K_M para ambos Qwen y SmolLM2, y Q8_0 para Llama, formatos que reducen la memoria necesaria con distinta precisión numérica. Las huellas de los pesos y sus licencias están en `data/tasks/models.json`: Apache-2.0 para Qwen y SmolLM2 y Community License para Llama [3, 4, 5, 6].

Para obtener respuestas variadas se usó temperatura 0,7 con top-p 0,9, top-k 40 y min-p 0. El contexto fue de 2048 tokens y el máximo de salida de 1024, con batch de 128, solicitud de 99 capas en GPU y `think=false` para desactivar el modo de pensamiento. Cada petición contenía un mensaje de usuario y no forzaba JSON. Las semillas 42, 43 y 44 controlaron el muestreo de las tres respuestas por tarea en la evaluación, y 42–45 las cuatro de Qwen3-8B para entrenamiento. Se conservaron respuestas, tiempos y tokens para poder recalcular métricas sin nuevas inferencias, aunque las semillas no garantizan igualdad entre motores o versiones.

5. Datos derivados para entrenamiento posterior

Con el diseño fijado, se usó exclusivamente train para crear dos productos: soluciones verificadas para ajuste supervisado (SFT) y pares de respuesta preferida y rechazada para optimización por preferencias (DPO). Las 90 tareas de train se distribuyen en nueve combinaciones de familia y nivel, con 10 tareas por combinación. Qwen3-8B generó cuatro respuestas por tarea, es decir, 40 por combinación y $90 \times 4 = 360$ en total, una escala elegida para muestrear variantes bajo el presupuesto de cómputo local.

El verificador aceptó 193 respuestas y clasificó las restantes como 154 errores numéricos y 13 no interpretadas. Al eliminar repeticiones textuales por tarea, ignorando diferencias de espacios, quedaron 178 candidatas para SFT. La revisión comenzó con cinco por combinación, seleccionadas con semilla 4303, y se amplió al detectar defectos hasta cubrir todas las candidatas. Se comprobó que datos, conversiones y operaciones concordaran con el problema, reteniendo 121 y descartando 57 por inconsistencias en el desarrollo. Esta revisión fue realizada por agentes de IA y no constituye certificación humana. Las 121 soluciones retenidas cubren 46 tareas y 20 problemas físicos.

Para DPO se emparejó una solución retenida con una respuesta inequívocamente incorrecta del mismo enunciado, con hasta dos pares distintos por tarea para limitar la repetición de ejemplos. Cuando Qwen3-8B no aportaba suficientes respuestas incorrectas para ese emparejamiento, se consultó al objetivo. Esa condición seleccionó 38 tareas de train y tres muestras por tarea produjeron $38 \times 3 = 114$ respuestas adicionales: 89 correctas, 19 errores numéricos y 6 no interpretadas. Solo los errores explícitos podían actuar como respuestas rechazadas, y al aplicar el límite de pares sin reutilizar sus miembros quedaron 35 pares de 25 tareas y 17 problemas físicos. De las 35 rechazadas, 22 proceden de Qwen3-8B y 13 del objetivo. Las cantidades finales son resultado del filtrado y los emparejamientos disponibles, no cuotas rellenadas artificialmente.

Familia	Dificultad	SFT	DPO
Velocidad	Fácil	27	3
Velocidad	Media	25	4
Velocidad	Difícil	22	11
Energía	Fácil	13	1
Energía	Media	10	5
Energía	Difícil	1	1
Luminosidad	Fácil	11	3
Luminosidad	Media	11	6
Luminosidad	Difícil	1	1
Total		121	35

Cuadro 2: Soluciones SFT y pares DPO retenidos tras verificación y revisión. Una tarea puede aportar más de una solución o par.

El volumen queda por debajo de las metas orientativas de 4000 SFT y 2000 DPO porque se priorizó revisar la calidad de una generación local acotada. Los 360 intentos de Qwen3-8B tomaron 2537,21 s y 56563 tokens, con 7,05 s por respuesta. A la tasa de retención observada, alcanzar 4000 SFT exigiría unas 23,30 horas solo de inferencia de Qwen3-8B. La escasez de una única solución en energía y luminosidad difíciles limita el entrenamiento posterior, por lo que estos datos preparan el experimento pero no demuestran suficiencia para aprender. La siguiente evaluación mide el desempeño previo a cualquier entrenamiento.

6. Línea base y análisis cualitativo

El conjunto test reúne seis problemas físicos por cada una de las tres familias, es decir, 18 problemas. Cada uno tiene tres niveles, de donde surgen las 54 tareas. Se obtuvieron tres respuestas por tarea y modelo, equivalentes a 162 intentos por modelo y 648 entre los cuatro locales. Pass@1 estima qué proporción de respuestas individuales es correcta, mientras pass@3 indica en qué proporción de tareas al menos uno de los tres intentos acierta, mostrando el beneficio de disponer de varios intentos.

Si una tarea tiene c aciertos entre $n = 3$ respuestas, el estimador es $\widehat{\text{pass@}}k = 1 - \binom{n-c}{k} / \binom{n}{k}$, promediado sobre las tareas. Para $k = 1$ equivale a $c/3$, y para $k = 3$ vale 1 si hay algún acierto y 0 si ninguno. Por ejemplo, 51,85 % en pass@1 de Qwen3-1.7B significa 84 aciertos entre 162 respuestas, y 68,52 % en pass@3 significa 37 tareas resueltas entre 54. Las tablas expresan ambas métricas y la cobertura en porcentajes, mientras "No interpretadas" es un conteo de respuestas. Los valores entre corchetes suponen correctas todas esas respuestas sin resolver y muestran el margen de incertidumbre por extracción. No son intervalos de confianza, y las variantes del mismo problema tampoco son observaciones independientes.

Modelo	pass@1 [sup.]	pass@3 [sup.]	Cobertura	No interpretadas
Qwen3-1.7B	51.85 [56.17]	68.52 [74.07]	95.68	7
Llama 3.2-1B	2.47 [58.02]	7.41 [100.00]	44.44	90
SmolLM2-1.7B	3.09 [79.63]	7.41 [100.00]	23.46	124
Qwen3-8B (generador)	50.62 [54.32]	72.22 [77.78]	96.30	6
DeepSeek-V4-Pro-0813	82.10 [100.00]	90.74 [100.00]	82.10	29

Cuadro 3: Línea base: porcentajes sobre 54 tareas y 162 respuestas por modelo. Entre corchetes, cota optimista si todas las no interpretadas fueran correctas; no es intervalo de confianza.

Modelo	Dificultad	pass@1 [sup.]	pass@3 [sup.]
Qwen3-1.7B	Fácil	62.96 [66.67]	72.22 [77.78]
Qwen3-1.7B	Media	55.56 [62.96]	72.22 [83.33]
Qwen3-1.7B	Difícil	37.04 [38.89]	61.11 [61.11]
Llama 3.2-1B	Fácil	5.56 [57.41]	16.67 [100.00]
Llama 3.2-1B	Media	0.00 [61.11]	0.00 [100.00]
Llama 3.2-1B	Difícil	1.85 [55.56]	5.56 [100.00]
SmolLM2-1.7B	Fácil	1.85 [77.78]	5.56 [100.00]
SmolLM2-1.7B	Media	5.56 [79.63]	11.11 [100.00]
SmolLM2-1.7B	Difícil	1.85 [81.48]	5.56 [100.00]
Qwen3-8B (generador)	Fácil	70.37 [70.37]	94.44 [94.44]
Qwen3-8B (generador)	Media	62.96 [62.96]	88.89 [88.89]
Qwen3-8B (generador)	Difícil	18.52 [29.63]	33.33 [50.00]
DeepSeek-V4-Pro-0813	Fácil	77.78 [100.00]	88.89 [100.00]
DeepSeek-V4-Pro-0813	Media	79.63 [100.00]	88.89 [100.00]
DeepSeek-V4-Pro-0813	Difícil	88.89 [100.00]	94.44 [100.00]

Cuadro 4: Resultados por dificultad: 18 tareas y 54 respuestas por fila. Corchetes: cota optimista de extracción, no intervalo de confianza.

En el objetivo, pass@1 es 62,96 % en fácil, 55,56 % en media y 37,04 % en difícil, y por familia alcanza 87,04 % en velocidad, 55,56 % en energía y 12,96 % en luminosidad. El promedio oculta, por tanto, una concentración de fallos en esta última familia. Ni el objetivo ni Llama tuvieron truncamientos o intentos incompletos, mientras SmolLM2 registró diez truncamientos y un intento incompleto entre sus 162 respuestas. Su cobertura de 23,46 % y cota optimista de 79,63 % hacen que el pass@1 automático de 3,09 % describa el sistema bajo este formato, sin aislar capacidad matemática. Sus cinco aciertos son de velocidad. Por su parte, Qwen3-8B obtuvo 82 aciertos, 74 errores numéricos y seis no interpretadas, con pass@1 de 50,62 %, pass@3 de 72,22 % y cobertura de 96,30 %, sin truncamientos ni intentos incompletos. La diferencia frente a los 84 aciertos del objetivo no demuestra superioridad estadística sobre esta muestra pequeña y relacionada.

Las 648 respuestas locales sumaron 2788,28 segundos de solicitudes y 153259 tokens de salida reportados. El intento incompleto de SmolLM2 no informó tokens y se conserva como dato faltante. Por modelo, Qwen3-1.7B consumió 435,12 s y 31521 tokens, Llama 395,58 s y 26414, SmolLM2 869,42 s y 71009, y Qwen3-8B 1088,16 s y 24315. No hubo cargos de API local y no se midió electricidad. Ollama informó que la memoria del modelo residió completamente en GPU en las 162 observaciones de cada modelo, lo que no equivale a medir toda la memoria del proceso ni el tamaño de los pesos en disco.

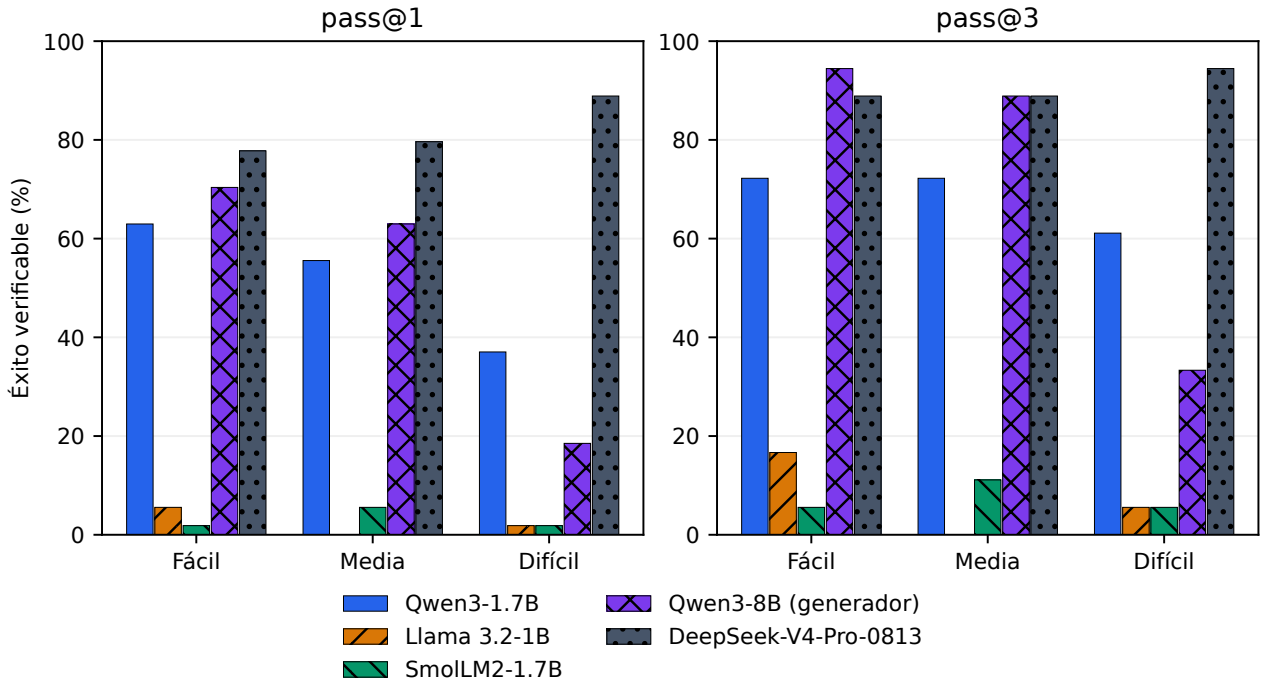


Figura 2: Evaluación con verificador común por dificultad. Cada nivel contiene 18 tareas y 54 respuestas por modelo.

Las respuestas permiten distinguir errores de cálculo de límites del verificador. En Qwen3-1.7B, una solución suma 2,936 y 0,734 km, convierte a 3670 m y divide por 150 s para obtener 24,47 m/s correctamente. Otra trata 0,25 min como 0,25 s y produce un resultado 60 veces mayor. En energía, 1022,27 J se acepta frente a 1016,452 J por quedar dentro del 1 %, aunque la multiplicación explicada sea incorrecta. En luminosidad, una respuesta termina en 30,7876 W correctamente pero afirma que 1 W equivale a 1000 erg/s, mostrando que acertar el valor final no certifica el razonamiento dimensional. También hay desarrollos coherentes que quedan no interpretados por su formato LaTeX.

Estos ejemplos ilustran comportamientos, sin estimar su frecuencia ni corregir manualmente las métricas. La baja cobertura de Llama, particularmente en luminosidad, impide atribuir todos sus fallos a capacidad matemática. Además, las diferencias de cuantización, formato de conversación, idioma y configuración de pensamiento limitan la atribución causal de resultados al tamaño del modelo. Para ampliar la comparación se evaluó también una referencia externa bajo las mismas tareas y reglas de verificación.

6.1. Referencia externa

DeepSeek-V4-Pro-0813 [7] se ejecutó mediante OpenRouter con el proveedor DeepInfra FP8 fijado, sin sustituciones automáticas y con presupuesto de USD 5. Antes del test se realizaron cinco controles independientes que dieron tres aciertos y dos respuestas no interpretadas, sin truncamientos, por USD 0,0029965, y no se ajustó el extractor a esos resultados.

Se mantuvieron los 54 enunciados, tres muestras por tarea y la configuración de muestreo local con semillas 42–44, máximo de 1024 tokens y razonamiento desactivado, sin herramientas ni JSON forzado. El servicio anuncia contexto de 1048576 tokens frente a 2048 locales, y la identificación de los pesos se limita al modelo fechado y proveedor, sin huella digital verificable. FP8 es la precisión anunciada por el proveedor. Estas diferencias impiden asumir que iguales parámetros produzcan un muestreo idéntico entre ejecuciones locales y remotas.

El test produjo 133 aciertos y 29 respuestas no interpretadas, con pass@1 de 82,10 %, pass@3 de 90,74 % y cobertura de 82,10 %. No se clasificaron errores numéricos ni de unidad, ni hubo truncamientos o intentos incompletos, pero las no interpretadas impiden concluir exactitud matemática perfecta y elevan ambas cotas optimistas al 100 %. Fácil, media y difícil alcanzaron respectivamente 77,78 %, 79,63 % y 88,89 % en pass@1, confirmando que los niveles no ordenan universalmente el rendimiento. Entre los falsos negativos hay una

respuesta correcta de 410,6 km/h que se rechaza porque mencionar que pi no se usa activa una regla conservadora de negación, y otra con JSON correcto tras un marcador narrativo sin cantidad. Ambas conservan su clasificación automática.

Las 162 solicitudes consumieron 25377 tokens de entrada y 22125 de salida, sin tokens de razonamiento reportados, en 341,14 s. El test costó USD 0,0905151 y el total con controles fue USD 0,0935116. La tarifa capturada era USD 1,30/2,60 por millón de tokens de entrada/salida [8, 9]. El gasto efectivo quedó por debajo del presupuesto autorizado de USD 5.

7. Uso y reproducción de tareas

El paquete incluye el informe, código y pruebas, tareas en `data/tasks/` y soluciones SFT y pares DPO en `data/training/`, con sus metadatos de procedencia y selección. README explica el contenido y el uso inicial, mientras REPRODUCING permite comprobar integridad, regenerar las particiones y verificar las respuestas de los datos derivados con Python 3.12, sin pesos ni credenciales.

Las métricas de línea base y calibración se presentan en este informe, sin incluir las corridas originales en el paquete. Una nueva inferencia necesita los modelos y motores identificados y puede producir respuestas distintas aun con las mismas semillas. Para consultar mayor detalle de las iteraciones y los resultados experimentales completos, puede solicitarse al equipo acceso a su repositorio de trabajo. Esta información complementaria no es necesaria para usar el paquete.

Referencias

[1] Z. Stojanovski, O. Stanley, J. Sharratt, R. Jones, A. Adefioye, J. Kaddour y A. Köpf. Reasoning Gym: Reasoning Environments for Reinforcement Learning with Verifiable Rewards. arXiv:2505.24760, 2025. `https://arxiv.org/abs/2505.24760`.

[2] I. Mirzadeh, K. Alizadeh, H. Shahrokhi, O. Tuzel, S. Bengio y M. Farajtabar. GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models. arXiv:2410.05229, 2024. `https://arxiv.org/abs/2410.05229`.

[3] Qwen. Qwen3-1.7B, model card oficial. Hugging Face, `Qwen/Qwen3-1.7B`. Consulta: 7 de noviembre de 2026.

[4] Qwen. Qwen3-8B, model card oficial. Hugging Face, `Qwen/Qwen3-8B`. Consulta: 7 de noviembre de 2026.

[5] Meta. Llama-3.2-1B-Instruct, model card oficial. Hugging Face, `meta-llama/Llama-3.2-1B-Instruct`. Consulta: 7 de noviembre de 2026.

[6] Hugging Face. SmolLM2-1.7B-Instruct, model card oficial. `HuggingFaceTB/SmolLM2-1.7B-Instruct`. Consulta: 7 de noviembre de 2026.

[7] DeepSeek / OpenRouter. DeepSeek V4 Pro 0813. `https://openrouter.ai/deepseek/deepseek-v4-pro-20260813`. Consulta: 7 de noviembre de 2026.

[8] OpenRouter. Provider Routing. `https://openrouter.ai/docs/guides/routing/provider-selection`. Consulta: 7 de noviembre de 2026.

[9] OpenRouter. Pricing. `https://openrouter.ai/pricing`. Consulta: 7 de noviembre de 2026.