Pontificia Universidad Católica de Chile
Escuela de Ingeniería
IIC-3694 Inteligencia Artificial Generativa

# Efecto del SFT previo en RL para razonamiento con unidades

Proyecto de investigación · Entrega 1: propuesta

Fernando Fajardo, Sebastian Palma, Benjamin Prieto y Rodrigo Ugarte · 11 de noviembre de 2026

## 1. Problema y pregunta de investigación

El proyecto estudiará cómo mejorar Qwen3-1.7B en problemas cuantitativos con unidades mediante postentrenamiento. Partimos del entorno construido en el desafío, que genera tareas en español y verifica sus resultados automáticamente, para comparar ajuste supervisado (SFT), aprendizaje por refuerzo con recompensa verificable (RL) y optimización directa de preferencias (DPO). Esta entrega formula la investigación y su protocolo tentativo, sin presentar entrenamientos del proyecto como ejecutados.

La pregunta principal es: *¿cómo influye realizar SFT antes de RL en la eficiencia de aprendizaje, frente a solo RL, solo SFT y DPO, bajo un presupuesto de cómputo comparable?* SFT podría facilitar que el modelo produzca soluciones válidas para recibir recompensa, aunque también podría consumir presupuesto sin mejorar la generalización. Por eso distinguiremos adaptación al formato, exactitud numérica y calidad del razonamiento.

La hipótesis de trabajo es que SFT previo mejora el rendimiento de validación por unidad de cómputo frente a iniciar directamente con RL. Se contrastará también la alternativa de que la mejora se concentre en el formato o desaparezca al contabilizar el costo de SFT. La revisión siguiente fundamenta esa comparación y delimita lo que sus antecedentes permiten esperar.

## 2. Antecedentes y relación con la propuesta

Stojanovski et al. (2025) presentan Reasoning Gym [1], una biblioteca de tareas generadas por código con dificultad controlable y verificación automática. Su diseño respalda utilizar un entorno propio para producir señal de recompensa y estudiar aprendizaje por dificultad, pero sus resultados no demuestran que nuestro conjunto de unidades tenga volumen o calibración suficientes para entrenar.

GSM-Symbolic, de Mirzadeh et al. (2024) [2], muestra variación del desempeño al cambiar valores y condiciones de problemas matemáticos. Esto motiva conservar variantes relacionadas en la misma partición y evaluar por familia y nivel, evitando atribuir generalización a un promedio global. Nuestro experimento compartirá fórmulas entre particiones, por lo que estudiará nuevas magnitudes y representaciones, no nuevos dominios de razonamiento.

Rafailov et al. (2023) [3] formulan DPO como entrenamiento directo con pares preferidos y rechazados, sin ajustar un modelo explícito de recompensa ni muestrear nuevas respuestas durante la actualización. Sus experimentos de preferencias motivan esta alternativa a RL, pero no establecen superioridad en tareas con verificación numérica. Aquí las preferencias procederán de soluciones verificadas y revisadas, y el reducido número inicial de pares será una limitación a controlar.

DeepSeekMath, de Shao et al. (2024) [4], introduce GRPO, que compara las recompensas de varias respuestas al mismo problema y prescinde del modelo de valor adicional de PPO. Sus resultados de RL parten de un modelo previamente ajustado con SFT, de modo que no resuelven directamente nuestra comparación con RL desde el checkpoint inicial. Proponemos GRPO para ambas ramas de RL, sujeto a comprobar memoria y tiempo en el hardware disponible. La menor carga respecto de PPO no garantiza que quepa en una GPU de 6 GiB.

Finalmente, Aleithan et al. (2024) [5] muestran mediante revisión manual que superar pruebas automáticas de programación puede ocultar soluciones problemáticas. Tomamos esa advertencia metodológica, sin trasladar

sus tasas a nuestro dominio: acompañaremos la recompensa numérica con una auditoría humana de respuestas exitosas. Así, el estudio relacionará desempeño medido con la validez de las soluciones que el modelo aprende a producir.

## 3. Entorno y datos disponibles

El entorno del desafío [6] contiene tres familias, entendidas como tipos de problema definidos por una fórmula: velocidad $v = d/t$, energía cinética $E = mv^2/2$ y luminosidad $L = 4\pi d^2 F$. Se proporcionan fórmula y equivalencias, por lo que el modelo debe componer operaciones y conversiones sin recordar constantes ni utilizar herramientas. Cada problema admite datos directos o sumas de distancias, masas o flujos y se presenta en tres niveles: sin conversiones, con una conversión de entrada o con dos entradas convertidas y, en velocidad y energía difíciles, también la salida.

Los 60 problemas físicos generan $60 \times 3 = 180$ tareas. Por cada familia se asignan 10 problemas a entrenamiento, cuatro a validación y seis a prueba, manteniendo juntas sus variantes. Esto produce 90, 36 y 54 tareas respectivamente. Por ejemplo, una tarea proporciona distancias de 4,08 y 1,02 km y un tiempo de 88 s, y pide $(d_1 + d_2)/t$ en m/s. La salida `57.95 m/s` es aceptable frente al resultado esperado 5100/88 m/s.

La función `reward(prompt, completion)` devuelve 1 si extrae un único resultado finito, de magnitud compatible y dentro del 1 % de la referencia, tras convertirlo al Sistema Internacional, y 0 en caso contrario. Las referencias se calculan por código y no se envían al modelo. El extractor puede rechazar formatos correctos y actualmente admite unidades equivalentes distintas de la solicitada, por lo que su recompensa no certifica todos los pasos ni obliga siempre a realizar la conversión de salida.

Disponemos de 121 soluciones SFT generadas por Qwen3-8B y 35 pares DPO, todos de entrenamiento y con procedencia registrada. Su revisión fue realizada por agentes, no certificada por humanos, y energía y luminosidad difíciles conservan solo una solución SFT cada una. Estos datos servirán como punto de partida, sujetos a revalidación y ampliación antes de fijar los experimentos. La línea base previa de Qwen3-1.7B fue 51,85 % en pass@1 y 68,52 % en pass@3, con cobertura de extracción de 95,68 %. Se obtuvo con Ollama y pesos GGUF cuantizados, y deberá repetirse si cambia la configuración para entrenar.

## 4. Comparación experimental propuesta

Se plantea un estudio de métodos existentes con implementaciones públicas. Todas las rutas partirán del mismo checkpoint inicial de Qwen3-1.7B, entendido como el modelo antes de nuestro ajuste adicional, y usarán los mismos enunciados, particiones y evaluación. La tabla resume qué información recibe cada estrategia y evita confundir la comparación de modelos del desafío con esta comparación de entrenamientos de un único modelo.

| Ruta | Procedimiento |
|---|---|
| Control | Evaluar el checkpoint inicial sin ajuste adicional. |
| Solo SFT | Ajustar con las soluciones correctas de entrenamiento. |
| SFT → RL | Aplicar SFT y continuar con GRPO y recompensa del verificador. |
| Solo RL | Aplicar GRPO desde el checkpoint inicial, sin SFT propio previo. |
| DPO | Ajustar desde el checkpoint inicial con pares preferidos/rechazados y referencia inicial fija. |

Primero se medirá un piloto de memoria y tiempo, a partir del cual se fijará un presupuesto $B$ de entrenamiento por ruta en hardware común. SFT seguido de RL contabilizará ambas fases dentro de $B$, mientras el control no consume ese presupuesto. Se registrarán horas de GPU, tokens y evaluaciones por separado, identificando también el costo compartido de generar datos. Así, una ventaja de SFT previo no podrá atribuirse simplemente a disponer de más entrenamiento.

La sensibilidad principal será la fracción de $B$ dedicada al SFT previo: se propone comparar 25 % y 50 %, dejando el resto para RL, si el piloto permite ejecutar ambas condiciones. Los demás hiperparámetros de RL se mantendrán comunes entre las ramas para estudiar el efecto de su inicialización. Los checkpoints se

seleccionarán con validación, nunca con el conjunto de prueba. Si los datos requieren ampliación, se hará antes de fijar la comparación y se conservará la separación por problema físico.

## 5. Evaluación, recursos y próximos hitos

Se medirán pass@1 y pass@3 con tres respuestas por tarea, por familia y nivel. Pass@1 estima la proporción de respuestas correctas y pass@3 la proporción de tareas resueltas al menos una vez entre tres intentos. Se conservarán cobertura, errores numéricos y respuestas no interpretadas para distinguir capacidad de cálculo de cumplimiento del formato. El muestreo será común a las cinco rutas, con semillas 42–44 y límites de generación fijados con validación.

La hipótesis se contrastará con curvas de pass@1 en validación frente al cómputo acumulado, incluyendo el SFT previo, y con el rendimiento final a igual $B$. Como complemento se auditará manualmente una muestra de hasta tres éxitos por familia, nivel y ruta, elegidos aleatoriamente cuando existan. Se revisarán datos, conversiones, operaciones y conclusión, informando por estrato el denominador y la proporción de éxitos genuinos sin corregir silenciosamente la recompensa automática.

Antes de entrenar se precisarán y probarán las políticas de formatos, unidades y respuestas contradictorias. Se revalidarán SFT y DPO si cambia la recompensa y se reservará un test independiente del ajuste, porque el test del desafío ya fue observado al diagnosticar límites. Todos los resultados finales se evaluarán con la misma versión final del verificador, preservando el historial de problemas, correcciones y reentrenamientos. La dependencia entre variantes y la escasez de algunas celdas limitarán las conclusiones estadísticas.

El recurso inicial confirmado es una RTX 3050 Laptop de 6 GiB. El piloto probará ajuste de pocos parámetros mediante adaptadores LoRA y respuestas acotadas, sin asumir que la inferencia previa demuestra viabilidad de RL. Otro colaborador podría aportar cómputo, pero no se considera disponible todavía. Si se cambia de GPU se repetirá el piloto y se compararán las rutas en condiciones equivalentes, sin tratar horas de equipos distintos como recursos idénticos. Las semillas de entrenamiento adicionales dependerán del cómputo que quede disponible.

Para el avance del 25 de noviembre se prevén el piloto, la adaptación del entorno, la nueva línea base y primeras curvas de entrenamiento. Para el cierre del 9 de diciembre se completarán las cinco rutas, sensibilidad, auditoría y análisis, junto con paper, poster y video. Esta propuesta delimita esos experimentos y sus riesgos sin adelantar mejoras que todavía no se han medido.

# Referencias


[1] Z. Stojanovski, O. Stanley, J. Sharratt, R. Jones, A. Adefioye, J. Kaddour y A. Köpf. Reasoning Gym: Reasoning Environments for Reinforcement Learning with Verifiable Rewards. 2025. https://arxiv.org/abs/2505.24760.

[2] I. Mirzadeh, K. Alizadeh, H. Shahrokhi, O. Tuzel, S. Bengio y M. Farajtabar. GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models. 2024. https://arxiv.org/abs/2410.05229.

[3] R. Rafailov, A. Sharma, E. Mitchell, S. Ermon, C. D. Manning y C. Finn. Direct Preference Optimization: Your Language Model Is Secretly a Reward Model. 2023. https://arxiv.org/abs/2305.18290.

[4] Z. Shao, P. Wang, Q. Zhu, R. Xu, J. Song, X. Bi, H. Zhang, M. Zhang, Y. K. Li, Y. Wu y D. Guo. DeepSeekMath: Pushing the Limits of Mathematical Reasoning in Open Language Models. 2024. https://arxiv.org/abs/2402.03300.

[5] R. Aleithan, H. Xue, M. M. Mohajer, E. Nnorom, G. Uddin y S. Wang. SWE-Bench+: Enhanced Coding Benchmark for LLMs. 2024. https://arxiv.org/abs/2410.06992.

[6] F. Fajardo, S. Palma, B. Prieto y R. Ugarte. Razonamiento cuantitativo con unidades: desafío de investigación. IIC-3694, Pontificia Universidad Católica de Chile, 2026. Informe y datos disponibles en el repositorio del desafío.