Pontificia Universidad Católica de Chile
Escuela de Ingeniería
IIC-3694 Inteligencia Artificial Generativa

Razonamiento cuantitativo con unidades

Desafío de investigación

Fernando Fajardo, Sebastian Palma, Benjamin Prieto y Rodrigo Ugarte · 7 de noviembre de 2026

1. Problema y alcance

Construimos un entorno de razonamiento cuantitativo con unidades en español para preparar el entrenamiento posterior de un modelo pequeño. En este desafío no se realiza entrenamiento SFT, DPO ni RL. Cada problema se responde en un turno, sin calculadora, intérprete ni otras herramientas. El prompt proporciona la fórmula, el valor de π cuando corresponde y las equivalencias necesarias; la tarea exige aplicar operaciones y conversiones, no recordar física.

El objetivo es Qwen3-1.7B. Se comparan Llama 3.2-1B y SmolLM2-1.7B-Instruct. Qwen3-8B genera las respuestas de entrenamiento y se evalúa como modelo abierto mayor; no se presenta como modelo de frontera. La aclaración docente exige al menos tres pequeños y admite justificar por recursos la omisión de modelos mayores. La ampliación con DeepSeek-V4-Pro-0813 se ejecuta mediante OpenRouter, con presupuesto autorizado de USD 5 y proveedor DeepInfra FP8 fijado. Los resultados se obtienen por inferencia; no se usa la credencial OpenAI.

2. Entorno y generación

Las familias son velocidad, $v = d/t$; energía cinética, $E = mv^2/2$; y luminosidad, $L = 4\pi d^2 F$. Cada familia admite un dato directo o la suma de dos componentes positivos: distancias, masas o flujos, respectivamente. Esta composición, las variantes físicas agrupadas y la verificación dimensional constituyen el aporte acotado del diseño. No se reclama originalidad por cambiar números. La generación procedural y su verificación tienen antecedentes en Reasoning Gym [1]; la sensibilidad a variantes tiene antecedentes en GSM-Symbolic [2].

El generador final `units-3` usa distancias de velocidad entre 101 y 9999 m y tiempos entre 7 y 199 s; masas y velocidades entre 1,1 y 49,9 en kg y m/s. Para luminosidad usa distancias enteras entre 2 y 30 m y flujos entre 0,01 y 0,99 W/m^2. Las componentes de una suma son positivas y su fracción se encuentra entre 0,2 y 0,8. Los datos visibles se representan con hasta 15 cifras significativas. Se excluyen cero, valores negativos e incertidumbres físicas.

Cada problema físico origina tres variantes. Fácil no requiere conversiones; media requiere una; difícil requiere tres en velocidad y energía, y dos en luminosidad, cuya salida se solicita en W. Se registran también estructura, operaciones y representación decimal o científica. Estas etiquetas describen el diseño; no demuestran una dificultad estrictamente ordenada ni permiten atribuir causalmente los errores solo a las conversiones.

Se generan 20 grupos por familia con semilla 4301 y se particionan por grupo con semilla 4302. Cada grupo mantiene juntas sus tres variantes. La identidad física se define por familia y magnitudes agregadas en SI, incluso cuando cambia la estructura o la unidad. Se excluyen 95 identidades observadas en spike, pilotos y controles. Las particiones contienen 90 tareas de train, 36 de eval y 54 de test: respectivamente 10, 4 y 6 grupos por familia. Cada celda familia/nivel tiene 10, 4 o 6 tareas; las dos estructuras están balanceadas. Hay 180 tareas, pero solo 60 problemas físicos distintos.

Las referencias son calculadas por código, nunca por el profesor. Un segundo cálculo interpreta los datos efectivamente impresos en el prompt y comprueba la referencia con tolerancia relativa 10^{-10}. Los archivos públicos omiten las referencias y la clave física; al modelo solo se envía el texto del prompt. Las plantillas se comparten entre particiones, por lo que el test evalúa nuevas magnitudes y combinaciones, no generalización a nuevos tipos de problemas o lenguaje arbitrario.

Por ejemplo, la tarea de train `14c34d569bd092efd278-medium` proporciona $d_1 = 4{,}08$ km, $d_2 = 1{,}02$ km y $t = 88$ s, pide $v = (d_1 + d_2)/t$ y explicita 1 km= 1000 m y 1 m/s= 3,6 km/h. La referencia privada es $5100/88 = 57{,}954545\ldots$ m/s. Un resultado terminal `57.95 m/s` recibe recompensa; `0 m/s` no. El prompt completo pide hasta 80 palabras de explicación en español y un único resultado, en JSON o cantidad/unidad, sin alternativas. Este ejemplo procede de train, no fue añadido tras observar test.

3. Recompensa y robustez

La interfaz es `reward(prompt, completion) ->float`. El consumidor carga un registro privado de prompts exactos; un prompt desconocido produce error de entrada. El extractor no recibe la referencia. Acepta un único resultado terminal inequívoco en JSON con `value` y `unit`, o como cantidad y unidad terminal, permitiendo un desarrollo anterior. No ejecuta expresiones.

Se convierte el resultado a SI y se comprueba dimensión, finitud y $|y - y^*| \leq 0{,}01|y^*|$. La tolerancia relativa del 1 % admite redondeo y es distinta de la usada para verificar la generación. Se aceptan m/s y km/h; J, kJ y erg; W, kW, erg/s y luminosidades solares. Una unidad equivalente puede recibir recompensa aunque difiera de la solicitada. Las pruebas incluyen 22 m/s frente a 79,2 km/h, 9 J y 4π W con referencias fijadas de forma independiente del generador.

Se rechazan resultados terminales contradictorios, alternativas, claves JSON duplicadas, valores no finitos y unidades incompatibles. No se rescata un número previo porque coincida con la referencia. Las etiquetas son `correct`, `numeric`, `unit` y `unparsed`. La última indica que falta un resultado admitido e inequívoco; no demuestra un error matemático. Truncamiento y respuesta incompleta del backend son marcas separadas, conservadas en el denominador.

El verificador final es `verifier-9`, congelado antes de la primera inferencia de test. La versión 9 añadió etiquetas terminales con signo igual y la unidad Watts observadas en controles de desarrollo de SmolLM2. En esos controles convirtió dos casos de no interpretados a numéricamente incorrectos; no añadió aciertos. No cambió etiquetas del piloto consolidado ni de las fuentes SFT/DPO. Se conservan ambas versiones, hashes, respuestas e IDs afectados: una mejora del evaluador no se presenta como mejora del modelo.

Persisten límites: ciertas frases compactas con LaTeX, expresiones finales sin evaluar y representaciones de miles no están cubiertas. Tras observar test no se amplió el parser. Se informa cobertura y una cota optimista que trata todas las no interpretadas como correctas; no es un intervalo de confianza. Un valor final aceptado tampoco certifica la coherencia de la explicación.

3.1. Limitaciones confirmadas en la revisión del equipo

La revisión del PR 3 se contrastó con código y respuestas guardadas, sin nuevas inferencias. Se mantiene `verifier-9`, los splits, SFT/DPO y todas las métricas publicadas. Esta ampliación documental no corrige etiquetas de test.

Caso	Comportamiento y alcance
Prompt desconocido	`reward` requiere `load_tasks` con los prompts exactos; lanza `ValueError` si no están registrados. El consumidor debe validar esta precondición antes de evaluar o entrenar.
Unidad solicitada	Se premia una cantidad físicamente equivalente aunque use otra unidad. Por ello, la recompensa no exige completar la conversión de salida que describe ciertos niveles difíciles.
Decimal o miles	Se interpreta coma o punto como decimal: `1,000 J` es 1 J y `3.380 J` es 3,38 J. El prompt no fija una convención de separadores de miles.
Longitud	La inferencia se limita a 1024 tokens, pero `reward` no impone un máximo propio de caracteres; no debe reutilizarse como protección de longitud en RL.
Formatos equivalentes	Alias como `joule`, `kph` y `Km/h`, números en palabras y ciertos superíndices quedan sin interpretar. La aceptación de equivalencias se limita al catálogo documentado.
Resultado intermedio	Una línea marcada como resultado que el parser no interpreta puede invalidar un JSON terminal numéricamente correcto, aun sin alternativas contradictorias.

Se confirmaron tres casos del último tipo en Qwen3-1.7B y cuatro en Qwen3-8B: al comprobar solo su JSON terminal, el valor pasa el 1 %. Esto daría 87/162 (53,70 %) y 86/162 (53,09 %) respectivamente, pero es un diagnóstico posterior al test, no una nueva evaluación ni una validación del desarrollo. Las cifras oficiales siguen siendo 84/162 y 82/162. Ejemplos: tarea `a6b709dd46414cbe8a02-hard`, muestra 2, del objetivo, y `2db7c9328fe1065496fc-hard`, muestra 2, del profesor. También se confirmó una respuesta de Llama aceptada en km/h cuando se pedía m/s; exigir la unidad solicitada reduciría sus aciertos de cuatro a tres.

Antes del entrenamiento del proyecto se prevé una versión 10 con pruebas de formatos equivalentes y contradicciones, convención numérica explícita, política de unidad de salida y límites de longitud e integración definidos. Se evaluarán las mejoras del PR 2 por separado, preservando la evidencia de la versión 9. Devolver cero ante cualquier error de integración podría ocultar un registro mal cargado; no se adopta como solución automática. Una recalificación futura de las respuestas conservadas se identificará como análisis posterior al test; evaluar de forma independiente un verificador ajustado con esos casos requiere un nuevo test reservado.

4. Calibración y protocolo experimental

El piloto inicial, independiente de los datos finales, mostró que luminosidad quedaba cerca del suelo. Se redujeron sus magnitudes y después se eliminó la conversión de salida difícil. Se preservaron las respuestas y versiones de cada piloto; se repitió inferencia cuando cambió el problema y solo se recalificaron respuestas cuando cambió el evaluador. El piloto consolidado comprende 90 tareas y 270 respuestas del objetivo: 132 correctas, 126 numéricas incorrectas y 12 no interpretadas; pass@1 de 48,89 %, pass@3 de 65,56 % y cobertura de 95,56 %. Hubo tres truncamientos, uno en luminosidad difícil; se conservaron en las métricas y respuestas originales.

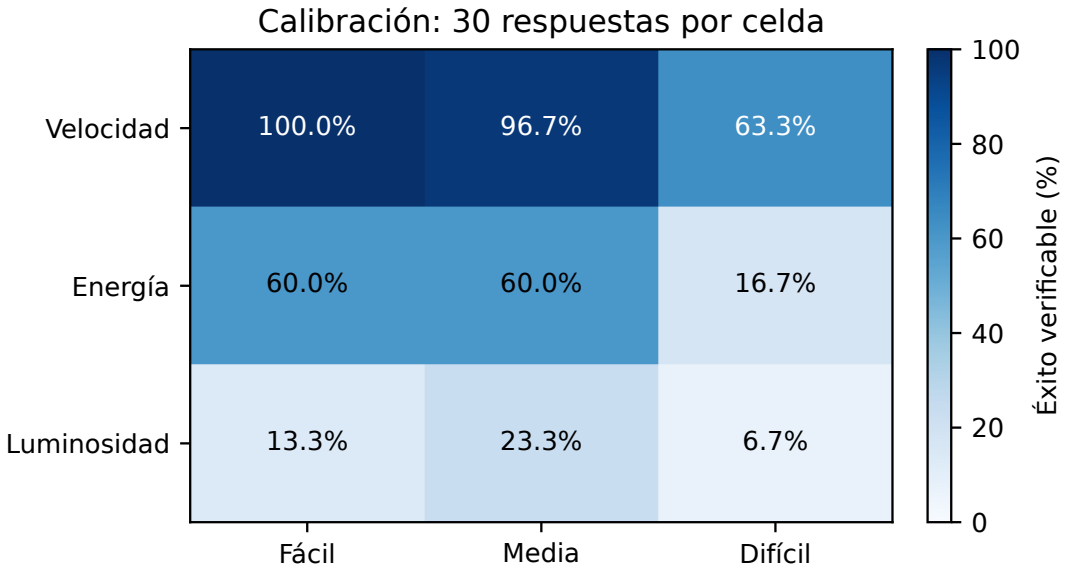


Figura 1: Piloto consolidado del objetivo, previo al congelamiento. Hay 30 respuestas por celda; son variantes relacionadas, no ensayos físicos independientes.

Luminosidad difícil permaneció en 2/30 aciertos y se retuvo como estrato de estrés. Velocidad fácil alcanzó 30/30 y se conservó como control; el nivel difícil de esa familia tuvo 19/30. Fácil y media no se separaron estrictamente en el promedio global (57,78 % y 60,00 %). El núcleo presenta aciertos y errores aprovechables, sin afirmar calibración suficiente de todas las celdas ni prometer mejora mediante entrenamiento.

El equipo real es Intel Core 5 210H, 12 CPU lógicas, 30,47 GiB de RAM y NVIDIA RTX 3050 Laptop con 6144 MiB. Driver 595.71.05; NVIDIA-SMI anuncia compatibilidad máxima CUDA 13.2, que no identifica el runtime usado por Ollama. El backend es Ollama 0.18.0; Python 3.12.13. Los pesos son GGUF: Qwen3-1.7B y Qwen3-8B Q4_K_M, Llama Q8_0 y SmolLM2 Q4_K_M. El catálogo conserva digest, licencia, template y metadata efectivamente observados. Los tamaños del backend (2,0B, 8,2B, 1,2B y 1,7B) difieren de algunas etiquetas comerciales. Qwen y SmolLM2 declaran Apache-2.0; Llama usa su Community License [3, 4, 5, 6].

Se usa un único proceso de inferencia local a la vez. Los parámetros enviados son temperatura 0,7; top-p 0,9; top-k 40; min-p 0; contexto 2048; batch 128; solicitud de 99 capas GPU; máximo 1024 tokens; y `think=false`. Cada solicitud tiene un mensaje de usuario, sin esquema JSON forzado. Las semillas son 42, 43 y 44 para la línea base y 42–45 para train del profesor. Se registran residencia en GPU, duración, tokens y respuesta completa. Los defaults no controlados se identifican por backend y template; no se afirma equivalencia de todas las opciones internas. Los servicios persistentes guardan cada respuesta con sincronización a disco y reanudan solo claves faltantes con configuración idéntica.

5. Datos derivados para entrenamiento posterior

Qwen3-8B produjo cuatro respuestas por cada una de las 90 tareas de train: 360 intentos, 193 aceptados por resultado, 154 errores numéricos y 13 no interpretados. Tras deduplicar texto por tarea salvo diferencias de espacios, hubo 178 candidatas correctas distintas. Se seleccionaron cinco candidatas por familia/nivel con semilla 4303, o todas si había menos. Un defecto obligó a ampliar la revisión a toda la celda. Además se revisaron todas las candidatas restantes; finalmente las 178 tienen juicio individual: 121 retenidas y 57 descartadas por calidad contextual. Esta auditoría fue realizada por un agente auxiliar y contrastada con los artefactos por el agente principal; no equivale a certificación humana ni a validación por el profesor.

Se conservan 121 trazas SFT de 46 tareas y 20 problemas físicos. Para DPO se emparejan respuestas retenidas con errores explícitos del mismo prompt, por orden de muestra, con máximo dos pares por tarea y sin reutilizar chosen ni rejected. No se usa producto cartesiano. Para completar negativos se consultó al objetivo tres veces sobre 38 tareas exactas de train: 114 respuestas, 19 errores numéricos y 6 no interpretadas, que no se usan como negativas. El resultado es 35 pares de 25 tareas y 17 problemas físicos: 22 rechazadas proceden del profesor y 13 del objetivo.

Familia	Dificultad	SFT	DPO
Velocidad	Fácil	27	3
Velocidad	Media	25	4
Velocidad	Difícil	22	11
Energía	Fácil	13	1
Energía	Media	10	5
Energía	Difícil	1	1
Luminosidad	Fácil	11	3
Luminosidad	Media	11	6
Luminosidad	Difícil	1	1
Total		121	35

Cuadro 1: Datos retenidos por familia y nivel. SFT fácil/media/difícil: 51/46/24; DPO: 7/15/13. Cobertura no equivale a balance suficiente.

Las cantidades están lejos de las metas orientativas de 4000 SFT y 2000 DPO. Se priorizó obtener datos trazables y revisar coherencia sin duplicarlos. La inferencia del profesor tomó 2537,21 s y generó 56563 tokens; media 7,05 s por respuesta. A la retención observada, 4000 SFT proyectarían unas 23,30 horas solo de profesor, sin garantizar igual calidad o diversidad. Se eligió una escala local acotada antes de congelar los splits. La existencia de una sola traza en energía y luminosidad difíciles es una limitación material para el proyecto posterior. No se afirma que estos datos basten para entrenar con éxito ni que el hardware haga imposible una generación más larga.

6. Línea base y análisis cualitativo

El test contiene 54 tareas de 18 problemas físicos, con tres muestras por modelo. Para una tarea con c aciertos en $n = 3$ intentos se usa $\widehat{\text{pass@}}k = 1 - \binom{n-c}{k}/\binom{n}{k}$ y se promedia entre tareas. pass@1 es $c/3$; pass@3 indica al menos un acierto observado. Las tablas usan porcentajes y se generan de las respuestas guardadas con la

misma versión final del verificador, sin nuevas inferencias. Los tríos no son observaciones independientes; no se reportan intervalos binomiales que ignoren esa dependencia.

Modelo	pass@1 [sup.]	pass@3 [sup.]	Cobertura	No interpretadas
Qwen3-1.7B	51.85 [56.17]	68.52 [74.07]	95.68	7
Llama 3.2-1B	2.47 [58.02]	7.41 [100.00]	44.44	90
SmolLM2-1.7B	3.09 [79.63]	7.41 [100.00]	23.46	124
Qwen3-8B (profesor)	50.62 [54.32]	72.22 [77.78]	96.30	6
DeepSeek-V4-Pro-0813	82.10 [100.00]	90.74 [100.00]	82.10	29

Cuadro 2: Línea base: porcentajes sobre 54 tareas y 162 respuestas por modelo. Entre corchetes, cota optimista si todas las no interpretadas fueran correctas; no es intervalo de confianza.

Modelo	Dificultad	pass@1 [sup.]	pass@3 [sup.]
Qwen3-1.7B	Fácil	62.96 [66.67]	72.22 [77.78]
Qwen3-1.7B	Media	55.56 [62.96]	72.22 [83.33]
Qwen3-1.7B	Difícil	37.04 [38.89]	61.11 [61.11]
Llama 3.2-1B	Fácil	5.56 [57.41]	16.67 [100.00]
Llama 3.2-1B	Media	0.00 [61.11]	0.00 [100.00]
Llama 3.2-1B	Difícil	1.85 [55.56]	5.56 [100.00]
SmolLM2-1.7B	Fácil	1.85 [77.78]	5.56 [100.00]
SmolLM2-1.7B	Media	5.56 [79.63]	11.11 [100.00]
SmolLM2-1.7B	Difícil	1.85 [81.48]	5.56 [100.00]
Qwen3-8B (profesor)	Fácil	70.37 [70.37]	94.44 [94.44]
Qwen3-8B (profesor)	Media	62.96 [62.96]	88.89 [88.89]
Qwen3-8B (profesor)	Difícil	18.52 [29.63]	33.33 [50.00]
DeepSeek-V4-Pro-0813	Fácil	77.78 [100.00]	88.89 [100.00]
DeepSeek-V4-Pro-0813	Media	79.63 [100.00]	88.89 [100.00]
DeepSeek-V4-Pro-0813	Difícil	88.89 [100.00]	94.44 [100.00]

Cuadro 3: Resultados por dificultad: 18 tareas y 54 respuestas por fila. Corchetes: cota optimista de extracción, no intervalo de confianza.

En el objetivo, pass@1 es 62,96 % en fácil, 55,56 % en media y 37,04 % en difícil; por familia es 87,04 % en velocidad, 55,56 % en energía y 12,96 % en luminosidad. La mezcla global no debe ocultar la concentración de dificultad en la última familia. No hubo truncamientos ni intentos incompletos del backend en Qwen3-1.7B ni en Llama. SmolLM2 tuvo diez truncamientos y un intento incompleto, conservados entre sus 162 respuestas; su cobertura fue 23,46 %. Por ello, su pass@1 automático de 3,09 % es una medida del sistema completo bajo este contrato, no una estimación fiable de exactitud matemática aislada. Su cota optimista alcanza 79,63 %, ilustrando la incertidumbre de extracción. SmolLM2 no tiene aciertos automáticos en energía ni en luminosidad; los cinco proceden de velocidad. Los ejemplos conservados incluyen el único intento con `done=false` y una respuesta que alcanza el límite de 1024 tokens. Qwen3-8B obtuvo 82 aciertos, 74 errores numéricos y seis no interpretadas: pass@1 de 50,62 %, pass@3 de 72,22 % y cobertura de 96,30 %, sin truncamientos ni intentos incompletos. Qwen3-1.7B tuvo 84 aciertos y pass@3 de 68,52 %. Estas diferencias sobre una muestra pequeña y relacionada no demuestran superioridad estadística de uno sobre otro. El profesor mayor no garantiza mejores respuestas ni datos automáticamente coherentes.

Las 648 respuestas locales de test sumaron 2788,28 segundos de solicitudes y 153259 tokens de salida reportados. Un intento incompleto de SmolLM2 no informó conteo de tokens; no se le asigna un conteo observado de cero. Por modelo, Qwen3-1.7B consumió 435,12 s y 31521 tokens; Llama, 395,58 s y 26414; SmolLM2, 869,42 s y 71009; y Qwen3-8B, 1088,16 s y 24315. El costo de API local es cero y no incluye electricidad. La memoria de modelo reportada por Ollama residió completamente en GPU en las 162 observaciones de cada modelo; no se atribuye esa cifra al tamaño de los pesos en disco ni a toda la memoria del proceso.

En Qwen3-1.7B, una respuesta suma 2,936 y 0,734 km, convierte a 3670 m y divide por 150 s para obtener

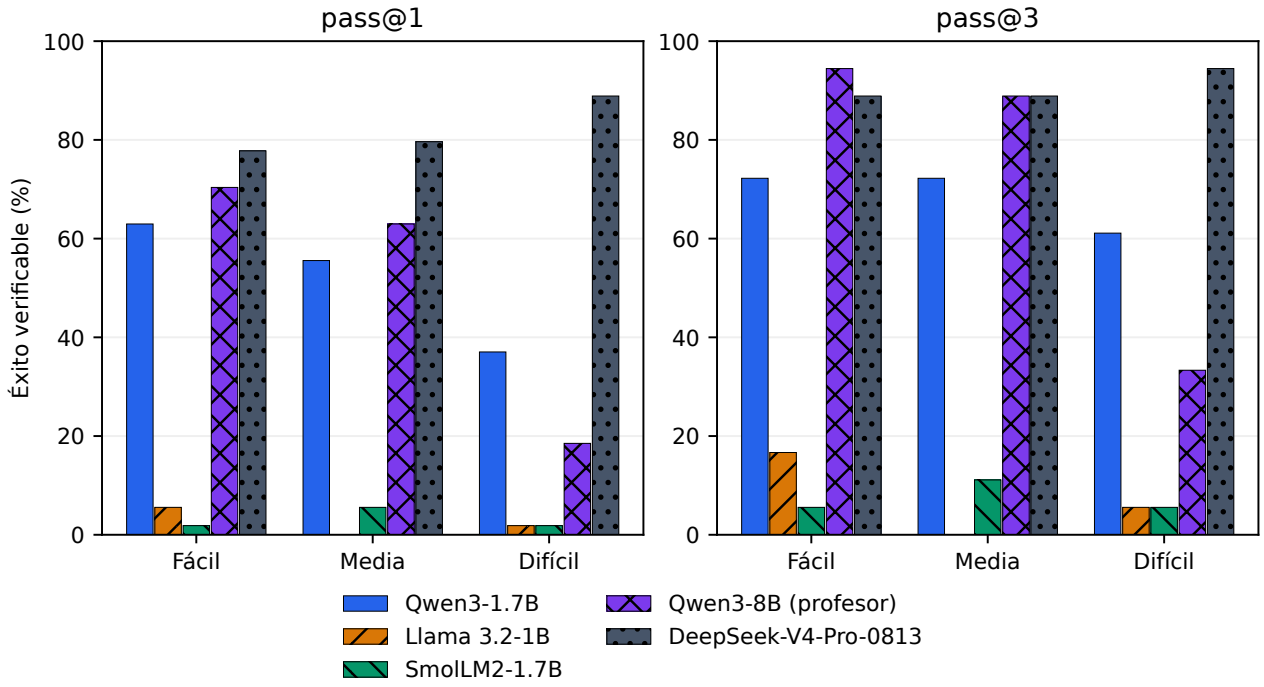


Figura 2: Evaluación con verificador común por dificultad; 18 tareas y 54 respuestas por modelo y nivel. Ver cobertura y categorías antes de interpretar diferencias.

24,47 m/s correctamente. Otra trata 0,25 min como 0,25 s y produce un resultado 60 veces mayor. En energía, 1022,27 J recibe aceptación frente a 1016,452 J por quedar dentro del 1 %, aunque la multiplicación descrita es incorrecta. En luminosidad, una respuesta termina correctamente en 30,7876 W pero afirma falsamente que 1 W equivale a 1000 erg/s: el número final no certifica razonamiento dimensional. Un párrafo con cálculo y redondeo coherentes termina en una estructura LaTeX no admitida y permanece `unparsed`; no se modifica su etiqueta.

Los ejemplos cualitativos conservan ID, índice de muestra, hash y juicio automático. Son ilustraciones seleccionadas, no una estimación de frecuencia de causas ni una corrección manual de las métricas. La baja cobertura de Llama, particularmente en luminosidad, impide atribuir todos sus fallos automáticos a capacidad matemática. Cuantizaciones y templates distintos, el idioma español y la configuración de pensamiento limitan la atribución causal de las diferencias a parámetros o familias de modelos.

7. Referencia externa mediante OpenRouter

Se eligió DeepSeek-V4-Pro-0813 [7], el candidato fechado disponible que cabe en el presupuesto autorizado de USD 5. La ruta efectiva se fijó en DeepInfra FP8, sin fallback ni cambio automático de modelo. El catálogo y la lista de endpoints públicos se conservaron con sus precios y parámetros. El proveedor nativo DeepSeek fue excluido por la política de privacidad de la cuenta antes de generar el primer control; no se modificó esa política. La ruta DeepInfra completó cinco controles de desarrollo fuera de test: tres aceptados y dos no interpretados, sin truncamientos, por USD 0,0029965. No se ajustó el parser a estos resultados.

Se usan los mismos 54 prompts congelados, tres respuestas por tarea, máximo 1024 tokens, temperatura 0,7, top-p 0,9, top-k 40, min-p 0 y semillas 42–44. Se solicita razonamiento desactivado, sin herramientas ni JSON forzado. La API anuncia contexto de 1048576 tokens, distinto del buffer local de 2048; los prompts cortos son idénticos. Los defaults y la implementación del muestreo son propios del servicio; igualdad de parámetros no implica equivalencia de motor ni reproducibilidad bit a bit. La revisión remota se identifica por modelo fechado y proveedor, sin un digest de pesos observable. FP8 procede del catálogo del endpoint, no de una inspección de sus pesos en ejecución.

La tarifa capturada de esa ruta es USD 1,30/2,60 por millón de tokens de entrada/salida. Se aplican caps de

1,32/3,96 y se reserva conservadoramente USD 0,02 antes de cada intento, también si falla, con un registro global que impide superar USD 5 reservados. Los prompts están limitados a 2048 bytes; la reserva cubre un margen de 6144 tokens de entrada y 1024 de salida a esos caps. El costo observado se conserva en cada respuesta. La política de precios y selección de rutas está documentada por OpenRouter [8, 9]. La reserva no es el importe facturado y los cargos por comprar créditos preceden a esta ejecución; no se hizo ninguna compra adicional.

El test externo produjo 133 respuestas aceptadas y 29 no interpretadas: pass@1 de 82,10 %, pass@3 de 90,74 % y cobertura de 82,10 %. No hubo respuestas clasificadas como numéricamente incorrectas, unidades incompatibles, truncamientos ni intentos incompletos. Esto no demuestra exactitud matemática perfecta: las 29 no interpretadas permanecen sin resolución automática y dan una cota optimista de 100 % para ambas métricas. Fácil/media/difícil tuvieron pass@1 de 77,78/79,63/88,89 %; la inversión nominal refuerza que los niveles no son una escala universal de capacidad. La revisión contextual y sus limitaciones se conservan separadas de las etiquetas. Por ejemplo, una respuesta convierte 0,9 min a 0,015 h y obtiene 410,6 km/h correctamente, pero la frase previa que aclara que pi no se usa activa una guardia conservadora de negación. Otra termina con un JSON numéricamente correcto tras un marcador narrativo sin cantidad en esa línea. Ambas permanecen no interpretadas: son falsos negativos de extracción observados, no errores matemáticos demostrados ni motivos para retocar el verificador después de test.

Las 162 solicitudes externas consumieron 25377 tokens de entrada y 22125 de salida, con cero tokens de razonamiento reportados; sumaron 341,14 s y USD 0,0905151. Con los cinco controles, el costo reportado fue USD 0,0935116. Se registraron 168 intentos incluyendo el rechazo previo a generar: reserva conservadora total de USD 3,36, por debajo del máximo autorizado. Todas las respuestas y costos son verificables sin repetir llamadas pagadas.

La revisión independiente encontró que cambiar accidentalmente la ruta del registro presupuestario podía reiniciar el contador al reanudar una corrida. Se vinculó esa ruta a la configuración y se añadió una regresión simulada. El código exacto de la inferencia anterior permanece en su snapshot; el recálculo con el adaptador corregido produjo etiquetas y métricas idénticas. Los cuatro módulos normativos, el verificador 9 y los prompts no cambiaron.

8. Reproducción y límites

El código central usa la biblioteca estándar. Las pruebas incluyen fixtures independientes, equivalencias, ataques al parser, referencias visibles, disjunción de grupos, reanudación y procedencia SFT/DPO. Los manifiestos SHA-256 fijan datos, configuración y cuatro módulos normativos. Se conservan versiones anteriores y registros de recálculo. Las figuras usan Matplotlib 3.11.2 en un grupo de dependencias opcional fijado en el lockfile.

La reproducción sin inferencia comprueba hashes, regenera las particiones, reconstruye SFT/DPO y vuelve a calcular etiquetas y métricas. No requiere Ollama, pesos ni credenciales. Repetir inferencia sí requiere los modelos y backend documentados; igualdad de semillas no garantiza igualdad bit a bit entre hardware o versiones. El costo API local es cero; electricidad no medida. La referencia externa usa la API autorizada de OpenRouter; no se realizó ningún entrenamiento.

El informe usa el template suministrado por el usuario, conservado en `template/` junto a sus huellas. El paquete reúne los cuatro entregables: entorno y tareas; descripción del diseño; datos SFT/DPO; e informe de línea base, robustez y calibración. Se acompaña de comandos, manifiesto y mapa de evidencia para contrastar contenido y resultados desde una copia aislada, sin archivos del repositorio original. La entrega por correo al profesor queda a cargo del equipo; no se realizó envío automático.

Referencias

[1] Stojanovski et al. Reasoning Gym: Reasoning Environments for Reinforcement Learning with Verifiable Rewards. arXiv:2505.24760, 2025.

[2] Mirzadeh et al. GSM-Symbolic: Understanding the Limitations of Mathematical Reasoning in Large Language Models. arXiv:2410.05229, 2024.

[3] Qwen. Qwen3-1.7B, model card oficial. Hugging Face, `Qwen/Qwen3-1.7B`. Consulta: 7 de noviembre de 2026.

[4] Qwen. Qwen3-8B, model card oficial. Hugging Face, `Qwen/Qwen3-8B`. Consulta: 7 de noviembre de 2026.

[5] Meta. Llama-3.2-1B-Instruct, model card oficial. Hugging Face, `meta-llama/Llama-3.2-1B-Instruct`. Consulta: 7 de noviembre de 2026.

[6] Hugging Face. SmolLM2-1.7B-Instruct, model card oficial. `HuggingFaceTB/SmolLM2-1.7B-Instruct`. Consulta: 7 de noviembre de 2026.

[7] DeepSeek / OpenRouter. DeepSeek V4 Pro 0813. `https://openrouter.ai/deepseek/deepseek-v4-pro-20260813`. Consulta: 7 de noviembre de 2026.

[8] OpenRouter. Provider Routing. `https://openrouter.ai/docs/guides/routing/provider-selection`. Consulta: 7 de noviembre de 2026.

[9] OpenRouter. Pricing. `https://openrouter.ai/pricing`. Consulta: 7 de noviembre de 2026.